

Projeto 03: Redes Neurais do zero com interpretabilidade

Breast Cancer Wisconsin (Diagnostic)

Rodrigo Banin Ferraz de Camargo (238257) • Caio Lima Albulquerque (288808)

Ricardo Andrade Oliveira Bello (247326)

1 de julho de 2026

1 Descrição da Implementação

Este projeto trata do desenvolvimento de um modelo de Rede Neural (MLP) de classificação binária a partir do conjunto de dados *Breast Cancer Wisconsin (Diagnostic)*, analisando-se a importância das *features* e discutindo-se as decisões feitas pelo modelo com base nas entradas.

A arquitetura da MLP foi implementada integralmente do zero utilizando apenas a biblioteca NumPy, com toda a lógica encapsulada na classe MLP. O fluxo do modelo contempla os seguintes componentes:


- **Forward pass:** São feitos cálculos vetorizados camada a camada ($Z^{(l)} = A^{(l-1)}W^{(l)} + b^{(l)}$), utilizando-se a função de ativação ReLU nas camadas ocultas e Softmax na camada de saída. Para garantir estabilidade numérica e evitar *overflow*, a implementação do Softmax subtrai o valor máximo de cada projeção antes da exponenciação ($Z_{estável} = Z - \max(Z)$).
- **Backpropagation:** Realizam-se cálculos exatos dos gradientes a partir da camada de saída ($\frac{\partial L}{\partial Z^{(L)}} = \text{softmax}(Z^{(L)}) - y_{\text{one-hot}}$), propagando o erro para as matrizes de pesos das camadas anteriores por meio da regra da cadeia e da derivada da ReLU. O *one-hot encoding* do alvo é tratado internamente.
- **Otimização:** O treinamento utiliza **Mini-Batch Gradient Descent**. Como funcionalidade extra, foi incorporada a atualização com momentum ($v \leftarrow \beta v - \alpha \frac{\partial L}{\partial W}$, $W \leftarrow W + v$) para acelerar a convergência e atenuar oscilações.
- **Inicialização e Função de Custo:** Os pesos adotam a inicialização avançada de He ($W \sim \mathcal{N}(0, \sqrt{2/\text{fan_in}})$) – ideal para redes com ativação ReLU – enquanto os vieses são inicializados em zero. A função de custo otimizada é a **Cross-Entropy** categórica ($L = -\frac{1}{N} \sum_{i=1}^N \log(\hat{y}_{i,y_i})$).

A arquitetura base utilizada para a maior parte dos experimentos possui a configuração [30, 64, 32, 2] (30 entradas correspondentes às features do *dataset*, 64 e 32 neurônios nas camadas ocultas, e 2 saídas para as classes benigno/maligno). Além dos métodos de treino (**train**) e predição (**predict**), a classe integra de forma nativa os três algoritmos de interpretabilidade aplicados neste estudo: mapas de saliência, perturbação e ablação, calculados diretamente sobre os tensores da rede.


2 Análise Exploratória de Dados

O conjunto de dados utilizados é composto por 569 instâncias e 30 atributos numéricos contínuos. Esses atributos são derivados da análise de imagens digitais de Aspiração por Agulha Fina (FNA) de massas mamárias. Eles descrevem características geométricas, topológicas e de textura dos núcleos celulares, computadas em três variantes para cada imagem: média, erro padrão e o "pior" valor (média dos três maiores valores).

A distribuição das classes apresenta um leve desbalanceamento, consistindo em 357 casos Benignos (62,7%) e 212 Malignos (37,3%), conforme ilustrado na Figura 1(a). Essa observação é fundamental, pois justifica a necessidade de utilizar um particionamento estratificado (*stratified split*) para separar os conjuntos de treino e teste posteriormente, garantindo a representatividade das classes. Além disso, é importante destacar que como os atributos originais operam em ordens de grandeza muito distintas (*e.g.* a área pode ultrapassar 2000, enquanto a suavidade opera na casa de 0.01), todos os dados foram submetidos a uma padronização estatística (*z-score*) antes de alimentar o modelo. A Figura 1(b) ilustra a dispersão das variáveis após a normalização (média 0 e desvio padrão 1), crucial para evitar que a MLP priorize pesos de *features* com maior magnitude absoluta durante o cálculo dos gradientes.



(a) Distribuição das classes.



(b) Boxplots padronizados por grupo (média, erro padrão, pior valor).

A análise das distribuições por meio de histogramas (Figura 2) revela que algumas características possuem um alto poder discriminativo de forma isolada. Atributos como `concave_points`, `perimeter` e `area` mostram uma clara separação espacial entre instâncias benignas e malignas, onde valores mais elevados estão fortemente associados à tumores malignos.






Figura 2: Distribuição das features de média por classe. `concave_points`, `perimeter` e `area` mostram clara separação entre benignos (verde) e malignos (vermelho).

O *pairplot* (Figura 3b) reitera que a combinação das *features* mais discriminativas forma agrupamentos bem definidos, indicando que um modelo não linear como a MLP terá capacidade robusta para modelar a fronteira de decisão. Adicionalmente, a matriz de correlação (Figura 3a) evidencia alta multicolinearidade entre variáveis estritamente geométricas, como raio, perímetro e área, que apresentam correlação de Pearson quase perfeita ($r > 0.95$).



(a) Correlação das features de média. `radius`, `perimeter` e `area` são altamente correlacionados ($r > 0.95$).




(b) Pairplot das 6 features mais discriminativas.

3 Treinamento e Avaliação

Para a avaliação do desempenho do modelo implementado, o conjunto de dados original foi particionado na proporção clássica de 80% para o conjunto de treinamento (455 instâncias) e 20% para o conjunto de teste (114 instâncias). Adotou-se explicitamente um critério de *stratified split* com o objetivo de preservar a proporção exata entre as classes benigna e maligna em ambos os subconjuntos, mitigando quaisquer distorções analíticas decorrentes do desbalanceamento original do *dataset*.

O modelo base para a consolidação das métricas foi estabelecido com a arquitetura [30, 64, 32, 2] (utilizando duas camadas ocultas), *learning rate* estável $\alpha = 0.01$, tamanho de mini-batch fixado em 32, e um horizonte de treinamento composto por 200 épocas. Os resultados estatísticos obtidos após a convergência dos pesos estão sumarizados na Tabela 1, disposta em paralelo ao comportamento histórico das curvas de aprendizado.


Métrica	Treino	Teste
Loss	0.0265	0.1027
Acurácia	0.9956	0.9825



A partir do treinamento executado do zero, observa-se que o classificador linear atingiu uma acurácia notável de 98.25% no conjunto de teste. A análise detalhada das curvas de treinamento revela importantes dinâmicas de otimização. Constata-se a ocorrência de um leve cenário de *overfitting* a partir da época ~ 40 , evidenciado pelo comportamento divergente das curvas de custo: enquanto a *loss* de treino decai de forma contínua em direção a zero, a *loss* de teste apresenta uma sutil inflexão ascendente. No entanto, esse início de memorização de ruído não resultou em prejuízos práticos para o modelo, visto que a curva de acurácia do conjunto de teste estabilizou-se de forma plana e resiliente até o final do processo, validando a robustez dos parâmetros aprendidos.


3.1 Impacto dos Hiperparâmetros

A flexibilidade do modelo desenvolvido permitiu mapear o comportamento da rede neural sob diferentes configurações operacionais. Os resultados empíricos desse mapeamento sistemático estão ilustrados na Figura 4.




(a) Taxa de aprendizado: $\alpha = 0.01$ é o melhor equilíbrio; $\alpha = 0.001$ lento; $\alpha = 0.1$ pode divergir.

(b) Tamanho do batch: 32 é o melhor custo-benefício entre ruído e velocidade.



(c) Arquitetura: 2 camadas $>$ 1 camada; ganho marginal além de 64+32 neurônios.



(d) Momentum: $\beta = 0.9$ com $\alpha = 0.01$ causa overshooting (95,6% vs 98,3%); passo efetivo ≈ 0.1 .

Analisando-se individualmente as variações de cada hiperparâmetro:


- **Learning Rate (α):** A configuração $\alpha = 0.01$ provou ser o ponto de equilíbrio ideal, permitindo passos consistentes rumo ao mínimo global. O uso de uma taxa reduzida ($\alpha = 0.001$) causou uma desaceleração extrema no aprendizado, tornando o modelo incapaz de convergir no tempo estipulado. Por outro lado, o aumento para $\alpha = 0.1$ gerou atualizações instáveis, fazendo com que os gradientes oscilassem violentamente ou divergissem da zona ótima.

- **Tamanho do Mini-Batch:** A escolha de um lote de tamanho 32 estabeleceu a melhor relação observada entre a velocidade de processamento e a introdução de ruído estocástico. Mini-batches menores funcionam como uma força regularizadora benéfica que auxilia o otimizador a escapar de mínimos locais rasos, mantendo uma estimativa de gradiente mais fiel do que uma abordagem puramente estocástica unitária.
- **Arquitetura da Rede:** O teste estrutural revelou que a transição de uma única camada oculta para uma composição hierárquica de duas camadas ([64, 32]) proveu um ganho expressivo na capacidade do modelo de delimitar a fronteira de decisão não linear. Contudo, a expansão para modelos ainda mais profundos ou excessivamente largos resultou em retornos marginais desprezíveis, aumentando apenas o custo computacional e acentuando a propensão ao *overfitting*.
- **Efeito do Momentum (β):** A aplicação do *momentum* ($\beta = 0.9$) associada à taxa padrão $\alpha = 0.01$ reduziu a acurácia de teste para 95.6% (contra os 98.3% obtidos sem ele). Isso ocorreu devido ao efeito colateral de *overshooting* (superpasso). Diante da inércia acumulada pelos gradientes passados, o passo efetivo cresceu para uma magnitude aproximada de 0.1, fazendo com que o otimizador acumulasse tanta velocidade que saltava sistematicamente por cima do ponto de mínimo global, impedindo o ajuste fino dos pesos nas fases finais do treino, evidenciando-se que a adição de *momentum* requer uma redução coordenada na *learning rate* base.


4 Interpretabilidade

Buscando garantir robustez às explicações, a análise de interpretabilidade do modelo não se limitou a uma única abordagem, mas sim três técnicas distintas foram implementadas e comparadas para entender como a MLP toma suas decisões, operando tanto em nível local (sensibilidade da instância) quanto global (importância estrutural):


- **Mapas de Saliência:** Avaliam a sensibilidade local do modelo calculando o gradiente da classe predita em relação às entradas da rede ($|\partial \hat{y}_c / \partial x_i|$), o que indica o quão rápido a probabilidade da classe mudaria caso um atributo específico sofresse uma perturbação infinitesimal.
- **Perturbação:** Avalia o impacto comportamental ao "mascarar" a informação, ou seja, para cada instância, o valor de uma *feature* é zerado e mede-se a queda na probabilidade da classe originalmente predita.
- **Ablação:** Uma técnica de intervenção estrutural onde o impacto de uma *feature* é medido removendo-a fisicamente da arquitetura (excluindo a coluna correspondente na matriz de entrada X e a respectiva linha na matriz de pesos da primeira camada, W_0).




(a) Saliency: sensibilidade local via gradiente.



(b) Perturbação: impacto ao zerar cada feature.



(a) Ablação: impacto ao remover a feature do modelo.



(b) Ablação progressiva: 10 features concentram a capacidade preditiva.

4.1 Features Mais Importantes

A análise comparativa (Figuras 5 e 6a) revela um forte consenso entre as três metodologias, com uma correlação de postos de Spearman superior a 0.85. As *features* consistentemente classificadas como as mais determinantes para o modelo foram: **worst_concave_points**, **worst_perimeter**, **mean_area**, **mean_concavity** e **worst_texture**. O teste de ablação cumulativa (Figura 6b) reforça esse achado, demonstrando que as 10 *features* mais importantes retêm praticamente toda a capacidade preditiva da rede neural, enquanto os 20 atributos restantes adicionam apenas ganhos marginais.

Sob a ótica da interpretação médica, as decisões do modelo estão perfeitamente alinhadas com o conhecimento citológico. Em exames de FNA, núcleos celulares com dimensões exageradas (perímetro e área), contornos irregulares (concavidades e pontos côncavos) e textura heterogênea são os marcadores visuais clássicos para o diagnóstico de tumores malignos.

Do ponto de vista matemático, também foi possível constatar que as técnicas de Perturbação e Ablação produziram resultados de importância equivalentes. Esse fenômeno é esperado dado o pré-processamento realizado, uma vez que como os dados foram padronizados via *z-score*, substituir uma entrada por zero (seu valor esperado basal) neutraliza matematicamente o produto interno daquela dimensão na primeira camada, surtindo o exato mesmo efeito que remover a linha correspondente da matriz de pesos W_0 .

4.2 Decisões Individuais

Para compreender o comportamento prático do modelo além das métricas globais, a interpretabilidade foi aplicada para analisar decisões a nível de instância (Figura 7), contemplando casos de sucesso (Verdadeiro Positivo e Verdadeiro Negativo) e falhas (Falso Positivo e Falso Negativo).

A análise das falhas revela as limitações inerentes aos dados. No caso do Falso Negativo (FN), o modelo diagnosticou a instância maligna como benigna porque a amostra apresentava níveis anormalmente baixos do atributo **worst_concave_points** (a *feature* de maior peso na rede). A ausência desse marcador crítico de irregularidade nuclear mascarou a malignidade perante o modelo. Por outro lado, o Falso Positivo (FP) ilustra um cenário de incerteza clínica (caso *borderline*). O modelo classificou o tumor benigno como maligno com uma probabilidade de 61.2% (relativamente baixa e indicativa de insegurança). Ao inspecionar as explicações locais, nota-se que a decisão foi forçada por uma concavidade excepcionalmente elevada para uma amostra benigna, o que induziu a rede neural ao erro ao priorizar a geometria do contorno sobre as demais métricas estabilizadoras.

Explicação de Decisões Individuais do Modelo




Figura 7: Quatro casos: VP, VN, FN e FP. O FN apresenta valores baixos de `worst_concave_points` mascarando malignidade; o FP mostra concavidade elevada em tumor benigno borderline ($P(M)=61,2\%$).

5 Discussão e Conclusão

O ecossistema de interpretabilidade implementado conferiu alto grau de confiabilidade ao classificador, uma vez que a forte convergência estatística verificada entre as três metodologias empregadas atua como um mecanismo de validação cruzada para as explicações. Sob a perspectiva do domínio de aplicação, as propriedades geométricas priorizadas de forma autônoma pelas camadas internas guardam correlação direta com os marcadores citológicos descritos na literatura médica para o diagnóstico de tumores malignos via agulha fina.

Por outro lado, o mapeamento sistemático do comportamento empírico trouxe à tona limitações metodológicas importantes que caracterizam oportunidades de refinamento. O desbalanceamento nativo entre as classes benigna e maligna foi preservado durante o treinamento, uma vez que estratégias ativas de rebalanceamento amostral ou ponderação de custos na perda não foram exploradas neste escopo. Outra vulnerabilidade identificada diz respeito à tendência de memorização de ruído observada a partir da época ~ 40 . A incorporação de mecanismos regulares de penalização estrutural (como *dropout*) cooperaria para atenuar esse cenário de leve *overfitting* e aprimorar a calibração probabilística da rede. Adicionalmente, as análises experimentais ficaram restritas a um particionamento estratificado estático único, de modo que a robustez estatística dos hiperparâmetros se beneficiaria de rotinas baseadas em validação cruzada *k-fold*.

O projeto estendeu as capacidades tradicionais de otimização ao suportar tanto a inicialização avançada de He quanto um fator paramétrico de *momentum* configurável para aceleração estocástica de gradientes. No domínio da explicabilidade, além do mapeamento de sensibilidade local baseado estritamente em gradientes obrigatórios formularam-se abordagens robustas fundamentadas em cenários de perturbação e ablação estrutural de sinapses.

Em síntese, o trabalho conclui com êxito o propósito de implementar uma arquitetura MLP completa e funcional construída do zero, atingindo um patamar notável de acurácia de 98.25% no diagnóstico do conjunto *Breast Cancer Wisconsin*. A calibração paramétrica ratifica que a combinação de uma taxa de aprendizado $\alpha = 0.01$, tamanho de lote fixado em 32 instâncias e uma volumetria oculta distribuída na configuração [30, 64, 32, 2] estabelecem as melhores condições operacionais para o mapeamento estável da fronteira de decisão. Por fim, as três técnicas de interpretabilidade cumprem seu papel analítico central, elucidando a lógica interna da caixa-preta computacional de forma perfeitamente alinhada ao conhecimento médico consolidado e desmistificando os determinantes locais que marcam tanto os acertos quanto os erros individuais do modelo.