

TP3 – Redes Neurais do Zero com Interpretabilidade

Breast Cancer Wisconsin (Diagnostic)

MC906 – Inteligência Artificial | Prof. Anderson Rocha


Junho de 2026

1 Descrição da Implementação

A MLP foi implementada integralmente do zero com NumPy (mlp.py, ~170 linhas): **forward pass** ($Z^{(l)} = A^{(l-1)}W^{(l)} + b^{(l)}$, ReLU nas escondidas, Softmax na saída), **backpropagation** ($\frac{\partial L}{\partial Z^{(L)}} = \text{softmax}(Z^{(L)}) - y_{\text{one-hot}}$), **atualização** com momentum ($v \leftarrow \beta v - \alpha \frac{\partial L}{\partial W}$, $W \leftarrow W + v$), **inicialização He** ($W \sim \mathcal{N}(0, \sqrt{2/\text{fan_in}})$). Arquitetura base: [30, 64, 32, 2], loss cross-entropy: $L = -\frac{1}{N} \sum_{i=1}^N \log(\hat{y}_i, y_i)$.

2 Análise Exploratória de Dados

569 instâncias, 30 features (10 características nucleares $\times$ 3 variantes: média, erro padrão, pior valor). Classes: 357 B (62,7%), 212 M (37,3%). Dados padronizados (z-score) antes do treinamento.



(a) Distribuição das classes.

(b) Boxplots padronizados por grupo (média, erro padrão, pior valor).






Figura 2: Distribuição das features de média por classe. `concave_points`, `perimeter` e `area` mostram clara separação entre benignos (verde) e malignos (vermelho).



(a) Correlação das features de média. **radius**, **perimeter** e **area** são altamente correlacionados ($r > 0,95$).




(b) Pairplot das 6 features mais discriminativas.

3 Treinamento e Avaliação


80% treino (455), 20% teste (114), split estratificado. Modelo base: [30, 64, 32, 2], $\alpha = 0,01$, batch=32, 200 épocas. Resultados:

Métrica	Treino	Teste
Loss	0,0265	0,1027
Acurácia	0,9956	0,9825




O modelo atinge 98,25% de acurácia no teste. Leve overfitting a partir da época ~ 40 (loss de treino cai enquanto a de teste sobe levemente), sem degradação da acurácia.


3.1 Impacto dos Hiperparâmetros




(a) Taxa de aprendizagem: $\alpha = 0,01$ é o melhor equilíbrio; $\alpha = 0,001$ lento; $\alpha = 0,1$ pode divergir.



(b) Tamanho do batch: 32 é o melhor custo-benefício entre ruído e velocidade.




(c) Arquitetura: 2 camadas $>$ 1 camada; ganho marginal além de 64+32 neurônios.




(d) Momentum: $\beta = 0,9$ com $\alpha = 0,01$ causa overshooting (95,6% vs 98,3%); passo efetivo $\approx 0,1$.

4 Interpretabilidade


Três técnicas: **Saliency Maps** ($|\partial \hat{y}_c / \partial x_i|$), **Perturbação** (queda na probabilidade ao zerar cada feature) e **Ablação** (remoção da linha de W_0 correspondente).




(a) Saliency: sensibilidade local via gradiente.



(b) Perturbação: impacto ao zerar cada feature.



(a) Ablação: impacto ao remover a feature do modelo.



(b) Ablação progressiva: 10 features concentram a capacidade preditiva.

4.1 Features Mais Importantes

As três técnicas convergem (Spearman $\rho > 0,85$) nas mesmas top features: **worst_concave_points**, **worst_perimeter**, **mean_area**, **mean_concavity** e **worst_texture**. **Interpretação médica:** núcleos maiores com contorno irregular (concavidades) e textura heterogênea são marcadores clássicos de malignidade em FNA. Perturbação e ablação produzem resultados equivalentes (zerar feature padronizada $\equiv$ remover linha de W_0).

4.2 Decisões Individuais

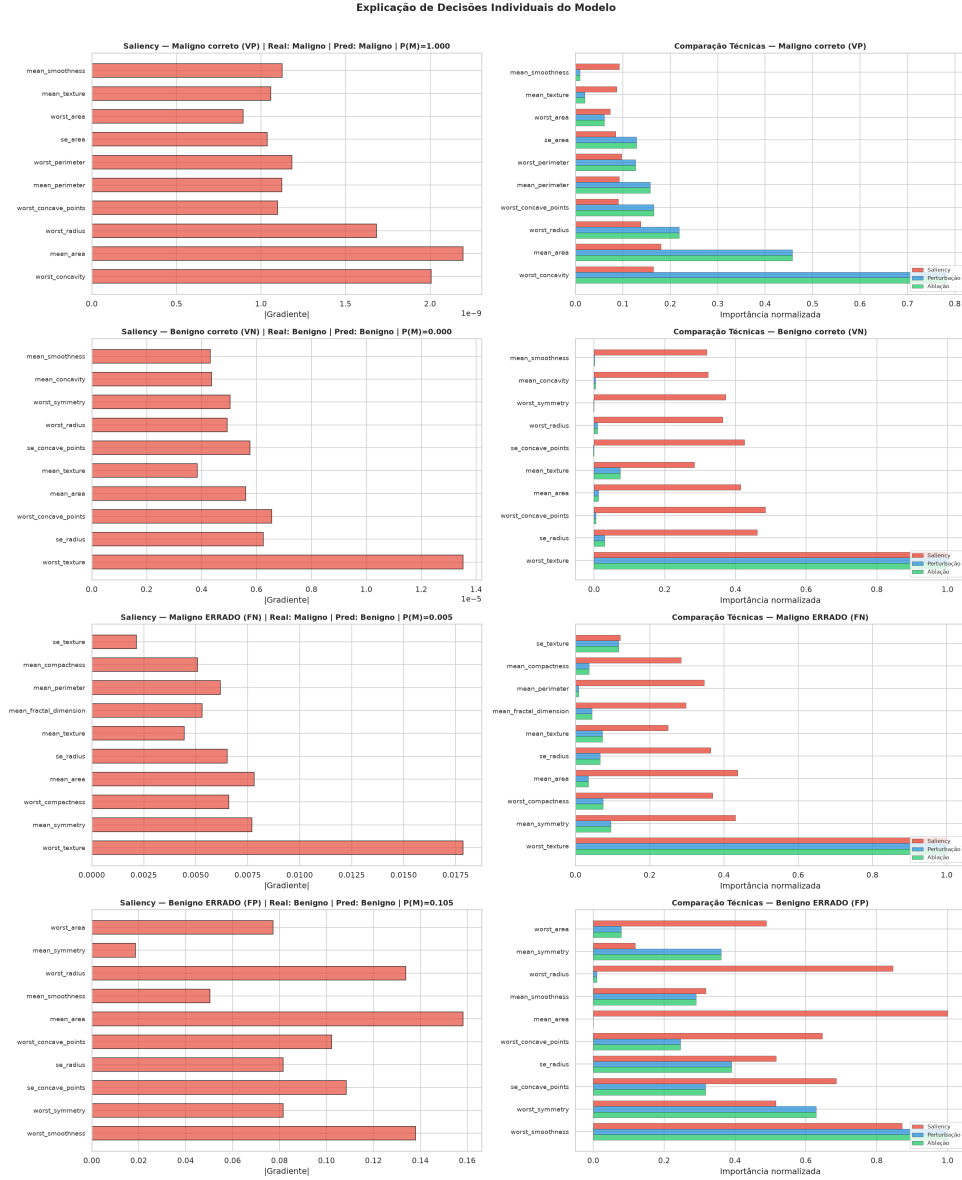


Figura 7: Quatro casos: VP, VN, FN e FP. O FN apresenta valores baixos de `worst_concave_points` mascarando malignidade; o FP mostra concavidade elevada em tumor benigno borderline ($P(M)=61,2\%$).

5 Discussão e Conclusão

Fortes: implementação do zero; três técnicas de interpretabilidade convergentes; features identificadas correspondem a marcadores citológicos conhecidos. **Limitações:** dataset desbalanceado (técnicas de rebalanceamento não exploradas); leve overfitting (regularização poderia melhorar calibração); experimentos com split único. **Extras:** inicialização He, momentum (β configurável), perturbação e ablação além dos gradientes obrigatórios.

Conclusão: implementação completa de MLP do zero atingindo **98,25% de acurácia** no Breast Cancer Wisconsin. $\alpha = 0,01$, batch=32 e arquitetura [30, 64, 32, 2] oferecem o melhor equilíbrio. As três técnicas de interpretabilidade identificaram features consistentes com o conhecimento médico e permitiram explicar decisões individuais, incluindo análise de erros.